Lab4

José Antonio García Ramirez

Marzo 15, 2018

Como el número de variables de nuestro conjunto de datos es pequeño, y además la muestra no se muy grande. Considere una primer exploración de matrices de gráficos de dispersión que también muestre la distribución marginal de cada variable y que distingue por 'Type' a las mediciones de los cráneos. La cual es la siguiente visualización:

```r
setwd('C:\\Users\\fou-f\\Desktop\\MCE\\Second\\EstadisticaMultivariada\\labs\\lab4')
craneos <- read.table(file ='Craneos.txt', header=TRUE) #se leen los datos
library(ggplot2)
library(GGally)
names(craneos)
```

```
## [1] "Length"   "Breadth"  "Height"   "Fheight"  "Fbreadth" "Type"
```

```r
craneos$Type <- factor(craneos$Type)
ggpairs(craneos, aes(color = Type), colums=1:7)
```

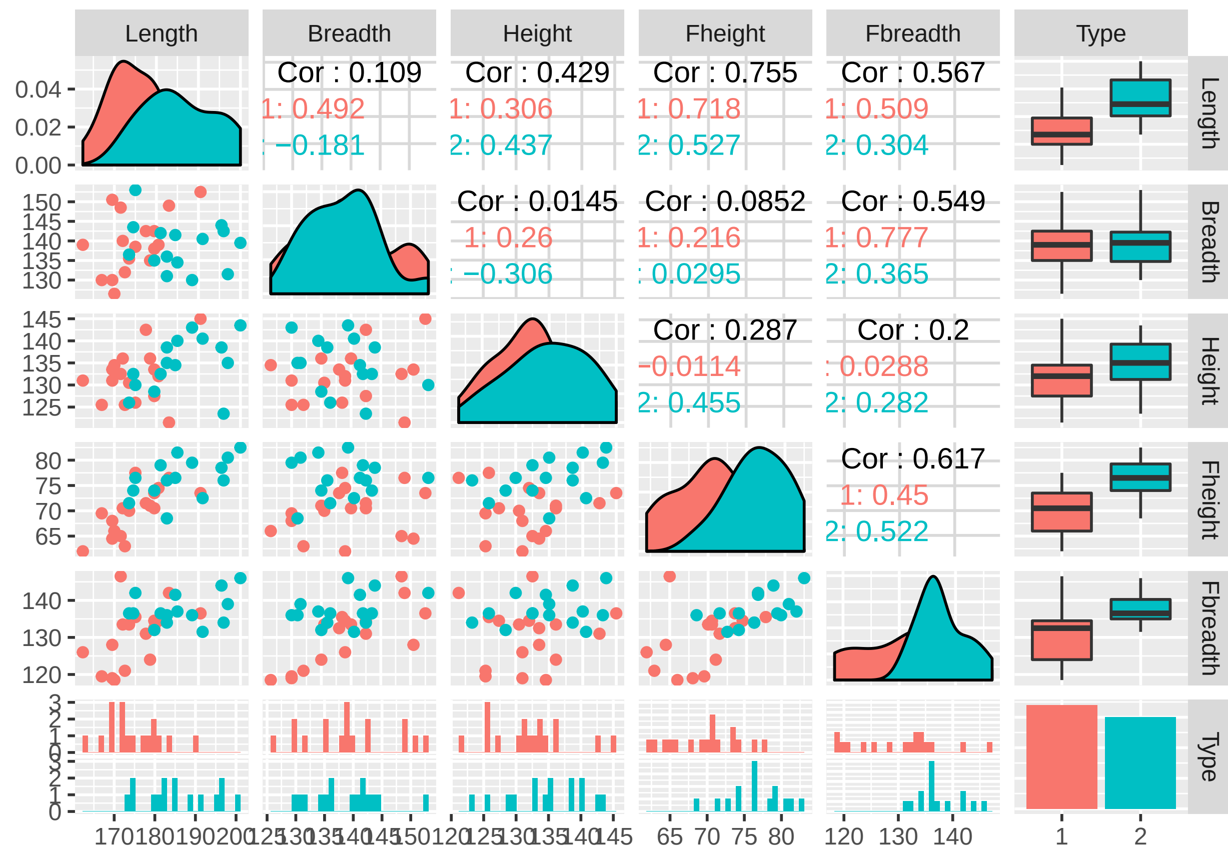

Del grafico de dispersión podemos ver que las variables 'Length, 'Fheight' y 'Fbreadth' separan a los grupos, en particular las tres presentan medianas diferentes para ambos grupos lo que nos induce a pensar que una prueba de medias considerando a cada registro de nuestro conjunto de datos como una muestra con distribución $N(\mu, \Sigma)$. Para ello, por lo menos applicamos test de normalidad (Shapiro-Wilks) sobre las variables univariadas.

```r
apply(craneos[,1:5], 2, shapiro.test)
```

```
## $Length
##
##  Shapiro-Wilk normality test
##
## data:  newX[, i]
## W = 0.96462, p-value = 0.3654
##
##
## $Breadth
##
##  Shapiro-Wilk normality test
##
## data:  newX[, i]
## W = 0.96847, p-value = 0.4583
##
##
## $Height
##
##  Shapiro-Wilk normality test
##
## data:  newX[, i]
## W = 0.97803, p-value = 0.7406
##
##
## $Fheight
##
##  Shapiro-Wilk normality test
##
## data:  newX[, i]
## W = 0.97875, p-value = 0.7626
##
##
## $Fbreadth
##
##  Shapiro-Wilk normality test
##
## data:  newX[, i]
## W = 0.93817, p-value = 0.06643
```

Los test indican que no hay indicios para descartar la normalidad univariada, por lo que "bruscamente" asumiré normalidad 5-variada. Y realizo una prueba de medias primero utilizando el estadístico T^2 suponiendo que la diferencia entre 'Fbreadth' y 'Fheight' es cero (es decir que la media de estos grupos es igual y por lo que se pueden diferenciar sin ambos grupos).

$$H_0 : \mu_{Fbreadth} - \mu_{Fheight} = 0$$

El objetivo planteado es rechazar H_0 asi que calculo el estadístico T^2.

```r
medias <- as.matrix(apply(craneos[,1:5], 2, mean))
```

Lo que me llevo tiempo de pensar, basándome en que en la tarea 3 demostré que $T2$ es invariante bajo transformaciones lineales invertibles, fue el construir una matriz A que segmentara los grupos y tomara las medias, para mi sorpresa el ejemplo se encuentra en el libro que estamos siguiendo de base. Así que solo replico lo que leí, lo importante desde mi perspectiva es que no asumo que las poblaciones tengan matrices de covarianzas diferentes (a diferencia de la prueba que vimos en el laboratorio, la cual me parece no necesaria, además de que induce un problema más complicado: el de comparar matrices de covarianza de dos poblaciones diferentes que hasta donde se puede realizar con el test de Levene, lo que justificado utilizar la versión ponderada).

El vector que lo efectua es el siguiente

```
library(xtable)
```

```
## Warning: package 'xtable' was built under R version 3.4.3
```

```
S <- cov(craneos[,1:5])
p <- dim(craneos[,1:5])[2]
n1 <- sum(craneos$Type==1)
n2 <- sum(craneos$Type==2)
n <- n1+n2
A1 <- matrix(c(0,0,0,1,-1), byrow = TRUE, ncol=1)
(A1)
```

```
##      [,1]
## [1,]    0
## [2,]    0
## [3,]    0
## [4,]    1
## [5,]   -1
```

Lo que induce una matriz de covarianzas $S%

```
S_y <- t(A1)%*%S%*%(A1)
```

Entonces sabemos que $E(Ax) = AE(x) = A\mu_x$ y $cov(Ax) = A\Sigma_x A$, como no conocemos Σ_x la estimó con la muestral S al igual que $\bar{\mu}_x$. Entonces tenemos el siguiente T^2:

```
medias <- mean(as.matrix(craneos[,1:5])%*%A1)
```

Y el estadístico T^2 muestral esta dado por :

```
n*(medias-0)*(S_y)^(-1)*(medias-0)
```

```
##          [,1]
## [1,] 3382.223
```

Mientras que el teorico con una confianza de 95% es de

```
sqrt(((p*(n-1))/(n-p))*qf(.95, df1=p, df2=n-p ))
```

```
## [1] 3.842464
```

Por lo que rechazamos la hippotesis de que la media conjunta sea la misma es decir que los grupos son identificables, por otro lado podemos considerar la prueba como univariada y comparar las medias asi cambiamos el estadístico T^2 por t_{n-1} y lo calculamos:

```
qt(.95, df=n-1)
```

```
## [1] 1.695519
```

Por lo que concluimos que aun univariadamente los grupos son identificables pues poseen medias diferentes.